

Análisis de Cancelación de Clientes

Telco Customer Churn

Documentación técnica del proyecto

Pipeline completo de análisis de datos · SQL + Tableau
Dataset: 7.043 clientes · 21 columnas · Kaggle

Michael Hans Evans — Data Analyst
Córdoba, Argentina

Índice

1. Resumen ejecutivo

Este documento describe el proyecto de análisis de cancelación de clientes (churn) realizado sobre el dataset Telco Customer Churn. El objetivo del análisis fue identificar por qué los clientes de una empresa de telecomunicaciones cancelan el servicio, qué segmentos concentran el mayor riesgo financiero, y traducir los hallazgos en recomendaciones accionables para retención.

El proyecto recorre el ciclo completo de trabajo de un analista de datos —obtención, exploración, limpieza, modelado relacional, análisis y visualización— utilizando SQL como motor central del pipeline, Python para validación estadística y Tableau Public para el reporte ejecutivo final.

Cifras principales del análisis

Indicador	Valor	Lectura
Total de clientes analizados	7.043	Base completa
Clientes que cancelaron	1.869	26,54%
Clientes activos	5.174	73,46%
Ingreso mensual total	\$456.116,60	Base de facturación
Ingreso mensual en riesgo	\$139.130,85	30,5% del total
Antigüedad promedio	32,4 meses	Todos los clientes

El hallazgo central del análisis es que la tasa de cancelación está fuertemente determinada por el tipo de contrato: los clientes con contrato mes a mes cancelan a una tasa quince veces superior a la de los clientes con contrato de dos años. Sobre esta base se identifican factores complementarios (método de pago, antigüedad, tipo de servicio de internet) y se cuantifica el ingreso en riesgo por segmento.

2. Fuente de datos

La primera etapa consistió en identificar la fuente, verificar la integridad del archivo y documentar sus características antes de cualquier transformación.

Origen y características

Atributo	Detalle
Nombre del dataset	Telco Customer Churn
Plataforma	Kaggle (publicado por IBM Sample Data Sets)
Archivo	WA_Fn-UseC_-Telco-Customer-Churn.csv
Formato / Encoding	CSV · UTF-8 · separador coma
Volumen	7.043 filas × 21 columnas
Naturaleza	Snapshot (corte transversal), no serie temporal
Granularidad	Una fila por cliente único (customerID)

Cada fila representa un cliente con sus atributos demográficos, el detalle de los servicios contratados, sus datos de facturación y la variable objetivo Churn (Yes/No), que indica si el cliente canceló el servicio.

Estructura de columnas

Grupo	Columnas	Tipo
Identificador	customerID	Texto único
Demográficas	gender, SeniorCitizen, Partner, Dependents	Categóricas
Contrato	tenure, Contract, PaperlessBilling, PaymentMethod	Mixtas
Telefonía	PhoneService, MultipleLines	Categóricas
Internet	InternetService + 6 servicios adicionales	Categóricas
Financieras	MonthlyCharges, TotalCharges	Numéricas
Objetivo	Churn	Categórica binaria

3. Hipótesis planteadas

Siguiendo una metodología rigurosa, las hipótesis fueron definidas antes de ejecutar el análisis —no de forma posterior a observar los datos— y cada una fue concluida como confirmada, rechazada o parcialmente confirmada con el dato concreto que la respalda. Se plantearon diez hipótesis agrupadas en seis áreas temáticas.

#	Área	Enunciado
H1	Contrato y permanencia	El tipo de contrato es el factor individual con mayor impacto en la cancelación. Los clientes con contrato mes a mes cancelan al menos 10 veces más que los de contrato de dos años.
H2	Contrato y permanencia	Dentro de cada tipo de contrato, los clientes con menos de 12 meses de antigüedad cancelan significativamente más que los de más de 48 meses.
H3	Perfil demográfico	Los clientes senior cancelan al menos 15 puntos porcentuales más que los no senior.
H4	Perfil familiar	Los clientes sin pareja ni dependientes son el segmento de mayor cancelación; los que tienen ambos, el de menor cancelación.
H5	Servicios de internet	Fiber optic tiene una tasa de cancelación superior al 40%, al menos el doble que DSL, señalando insatisfacción con el servicio premium.
H6	Servicios de protección	Los clientes sin OnlineSecurity ni TechSupport cancelan al menos el doble que los que tienen ambos servicios.
H7	Cantidad de servicios	Existe una relación inversa entre la cantidad de servicios contratados y la cancelación.
H8	Método de pago	El pago con cheque electrónico tiene una tasa de cancelación significativamente mayor que los métodos

#	Área	Enunciado
		automáticos.
H9	Riesgo financiero	La combinación de cargo mensual alto y contrato mes a mes concentra la mayor proporción del ingreso en riesgo.
H10	Facturación	Los clientes con factura electrónica cancelan más que los que reciben factura física.

4. Exploración de datos (EDA)

El análisis exploratorio se ejecutó en SQL (sobre la tabla cruda en SQLite) y se complementó con Python para los cálculos estadísticos que SQL no resuelve de forma nativa (asimetría, curtosis y asociación entre variables categóricas). El notebook 01_eda.ipynb está organizado en doce secciones.

Qué se hizo y cómo

Proceso	Cómo se ejecutó
Complejidad y confiabilidad	Conteo de registros, verificación de unicidad de customerID, descripción de la fuente y sesgos
Perfilado de columnas	Clasificación de cada columna por tipo almacenado, tipo semántico y rol en el modelo
Valores nulos	Detección de nulos reales y de espacios en blanco; análisis del patrón de ausencia
Duplicados	Verificación de duplicados exactos y por clave de negocio
Estadística descriptiva	Media, mediana, desvío, CV, asimetría y curtosis de las variables numéricas (Python/scipy)
Outliers	Método IQR y z-score, con validación de negocio
Variables categóricas	Frecuencia, cardinalidad y tasa de cancelación por categoría
Correlaciones	Pearson entre numéricas y Cramér's V entre categóricas vs Churn

Resultado del EDA

El dataset resultó estar en buen estado general. Los hallazgos principales fueron:

- **Problema de calidad detectado:** la columna TotalCharges estaba almacenada como texto y contenía 11 registros con espacios en blanco. Estos 11 registros corresponden exactamente a clientes con antigüedad cero (tenure = 0), lo que clasifica el patrón de ausencia como MCAR con justificación de negocio: no existe cargo acumulado para un cliente que lleva cero meses.
- **Sin duplicados ni nulos reales:** customerID es único en las 7.043 filas y no hay valores nulos en el resto de las columnas.
- **Asociación con la cancelación:** el análisis de Cramér's V mostró que el tipo de contrato es la variable categórica más asociada a la cancelación, seguida de los servicios de seguridad y soporte. El género resultó prácticamente sin relación con la cancelación.

- **Consistencia de servicios:** los clientes sin internet figuran de forma coherente con la etiqueta 'No internet service' en todas las columnas de servicios dependientes, sin inconsistencias.

5. Preparación de datos (ETL)

La limpieza y transformación se ejecutó íntegramente en SQL sobre SQLite, respetando un orden de dependencias estricto para que ninguna transformación invalidara a otra: primero la corrección de tipos, luego el tratamiento de nulos, la deduplicación, la estandarización de texto, el tratamiento de outliers y por último la generación de columnas calculadas.

Decisiones de limpieza

Paso	Decisión	Justificación
Corrección de tipos	TotalCharges a numérico; SeniorCitizen a texto categórico	Coherencia entre tipo almacenado y semántico
Tratamiento de nulos	Imputar los 11 blancos de TotalCharges con 0.0	Sin meses activos no hay cargo acumulado (MCAR)
Deduplicación	Sin acción (0 duplicados)	Verificación formal: el dataset no tenía duplicados
Estandarización	TRIM sobre todas las columnas de texto	Prevención de duplicados semánticos
Outliers	Mantener todos los registros	Los valores extremos tienen sentido de negocio
Eliminación de columnas	Ninguna columna eliminada	Todas aportan al modelo o al análisis

Columnas calculadas generadas

Para habilitar el análisis de las hipótesis se derivaron siete columnas nuevas, todas calculables a partir del dato original:

Columna	Definición	Hipótesis
Churn_num	Churn convertido a 1/0	Todas
tenure_group	Antigüedad agrupada en 4 rangos	H1, H2
perfil_familiar	Combinación de Partner y Dependents	H4
n_servicios	Cantidad de servicios adicionales (0 a 6)	H7
rango_cargo	MonthlyCharges agrupado en 4 rangos	H9
segmento_riesgo	Cargo alto + contrato mes a mes	H9

Resultado: un dataset limpio de 7.043 filas y 28 columnas, exportado a CSV y Excel. Las métricas clave (tasa de cancelación, ingreso total, ingreso en riesgo) coinciden al centavo entre el CSV, el Excel y la base de datos SQLite.

6. Modelado relacional

A partir del dataset limpio se diseñó un modelo dimensional normalizado. Se identificaron las entidades de negocio naturales y se separó la información en tablas de dimensiones (atributos descriptivos) y una tabla de hechos (las métricas del cliente).

Diseño del modelo

Se optó por un esquema en estrella (Star Schema) con una tabla puente, normalizado hasta la tercera forma normal (3FN). La decisión de diseño más relevante fue resolver la relación muchos-a-muchos entre clientes y servicios mediante una tabla puente con clave primaria compuesta, en lugar de mantener los servicios desnormalizados como columnas.

Tabla	Registros	Rol
dim_genero	2	Catálogo de género
dim_tipo_contrato	3	Catálogo de contrato
dim_metodo_pago	4	Catálogo de método de pago
dim_tipo_internet	3	Catálogo de internet
dim_catalogo_servicios	8	Catálogo de servicios
dim_cliente	7.043	Dimensión de cliente
fact_cliente	7.043	Tabla de hechos
bridge_cliente_servicio	56.344	Tabla puente (N:M)

Decisiones de diseño y alternativas descartadas

- **Claves subrogadas en los catálogos** en lugar de claves naturales de texto, por estabilidad y eficiencia en los JOINS.
- **Tabla puente para la relación N:M** en lugar de mantener los servicios como columnas, para cumplir 3FN y resolver correctamente la relación cliente-servicio.
- **dim_genero separada** porque el género es texto y como atributo directo violaría 3FN; SeniorCitizen, en cambio, se mantuvo en dim_cliente por ser binario.
- **SCD Tipo 1** es suficiente: el dataset es un snapshot sin historial temporal, por lo que no se requiere rastrear cambios.

La integridad referencial del modelo fue validada: no existen registros huérfanos en ninguna clave foránea, y todas las claves primarias (incluida la compuesta de la tabla puente) son únicas.

7. Análisis y resultados

El análisis se ejecutó en SQL puro utilizando CTEs, funciones de ventana (RANK, PARTITION BY) y subconsultas, con validación cruzada en Python. Cada hipótesis se analizó en al menos dos niveles de granularidad. A continuación se presentan los resultados de las diez hipótesis.

H1 — Tipo de contrato (CONFIRMADA)

Tipo de contrato	Clientes	Tasa de cancelación
Month-to-month	3.875	42,71%
One year	1.473	11,27%
Two year	1.695	2,83%

El contrato mes a mes cancela 15 veces más que el de dos años, superando el umbral de 10x planteado. Es el factor individual de mayor impacto en todo el análisis.

H2 — Antigüedad (CONFIRMADA)

Antigüedad	Clientes	Tasa de cancelación
0-12 meses	2.186	47,44%
13-24 meses	1.024	28,71%
25-48 meses	1.594	20,39%
49-72 meses	2.239	9,51%

La cancelación decrece de forma monótona con la antigüedad: los primeros 12 meses concentran casi la mitad de las cancelaciones. La relación se sostiene dentro de cada tipo de contrato.

H3 — Clientes senior (CONFIRMADA)

Segmento	Clientes	Tasa de cancelación
Senior	1.142	41,68%
No senior	5.901	23,61%

Diferencia de 18 puntos porcentuales, por encima del umbral de 15pp planteado.

H4 — Perfil familiar (CONFIRMADA)

Perfil familiar	Clientes	Tasa de cancelación
Sin pareja ni dependientes	3.280	34,24%
Con pareja, sin dependientes	1.653	25,41%
Sin pareja, con dependientes	361	21,33%
Con pareja y dependientes	1.749	14,24%

Diferencia de 20 puntos porcentuales entre los extremos. El vínculo familiar actúa como factor de retención.

H5 — Tipo de internet (CONFIRMADA)

Tipo	Clientes	Cargo prom.	Tasa cancelación
Fiber optic	3.096	\$91,50	41,89%
DSL	2.421	\$58,10	18,96%
Sin internet	1.526	\$21,08	7,40%

Fiber optic cancela 2,2 veces más que DSL pese a ser el servicio de mayor cargo. Esto sugiere insatisfacción con la calidad o el precio del servicio premium, no falta de servicio.

H6 — Servicios de protección (CONFIRMADA)

Servicios de seguridad/soporte	Clientes	Tasa de cancelación
Ningún servicio	4.079	33,42%
Solo uno de los dos	1.865	21,82%
Ambos servicios	1.099	9,01%

Los clientes sin OnlineSecurity ni TechSupport cancelan 3,7 veces más que quienes tienen ambos. Los servicios de protección funcionan como ancla de retención.

H7 — Cantidad de servicios (PARCIALMENTE CONFIRMADA)

Nº de servicios	Clientes	Tasa de cancelación
0 servicios	2.219	21,41%
1 servicio	966	45,76%
2 servicios	1.033	35,82%
3 servicios	1.118	27,37%
4 servicios	852	22,30%
5 servicios	571	12,43%
6 servicios	284	5,28%

Anomalía relevante: los clientes con un solo servicio presentan la tasa más alta (45,76%), por encima incluso de quienes no tienen ninguno. A partir de dos servicios la relación es claramente inversa: a más servicios, menos cancelación, hasta el 5,28% con seis servicios. La hipótesis se confirma de forma parcial.

H8 — Método de pago (CONFIRMADA)

Método de pago	Clientes	Tasa de cancelación
Electronic check	2.365	45,29%
Mailed check	1.612	19,11%
Bank transfer (automatic)	1.544	16,71%
Credit card (automatic)	1.522	15,24%

El cheque electrónico cancela 3 veces más que la tarjeta de crédito automática. El pago automático se asocia a mayor permanencia.

H9 — Rango de cargo y riesgo financiero (CONFIRMADA con matiz)

Rango de cargo mensual	Clientes	Tasa de cancelación
Bajo ($\leq$ \$35)	1.735	10,89%
Medio (\$35-65)	1.409	23,14%
Alto (\$65-95)	2.604	35,94%
Muy alto ($>$ \$95)	1.295	32,28%

La relación entre cargo y cancelación no es lineal: el pico de cancelación está en el rango alto (\$65-95) y desciende levemente en el rango muy alto, donde los clientes suelen tener más servicios contratados y mayor compromiso. El segmento de cargo alto combinado con contrato mes a mes concentra el mayor ingreso en riesgo.

H10 — Facturación electrónica (CONFIRMADA)

Facturación	Clientes	Tasa de cancelación
Factura electrónica	4.171	33,57%
Factura física	2.872	16,33%

Los clientes con factura electrónica cancelan el doble que los de factura física. El efecto se mantiene al controlar por tipo de contrato.

8. Segmentos de mayor riesgo financiero

Más allá de las tasas de cancelación, se cuantificó el ingreso mensual en riesgo por segmento, cruzando las condiciones de mayor impacto. Esto traduce el problema de churn a términos económicos para priorizar la acción comercial.

Segmento	Ingreso en riesgo	Clientes
Cargo alto + contrato mes a mes	\$102.177	1.186
Fiber optic + cheque electrónico	\$74.346	849
Clientes nuevos sin servicios adicionales	\$41.284	706

Los porcentajes de cada segmento se solapan porque un mismo cliente puede pertenecer a más de un segmento. El segmento de cargo alto con contrato mes a mes es el más crítico: 1.186 clientes concentran \$102.177 de ingreso mensual en riesgo, la mayor oportunidad individual de retención.

9. Conclusiones y recomendaciones

El análisis confirma que la cancelación de clientes está concentrada en perfiles identificables y, por lo tanto, es accionable. El tipo de contrato, el método de pago y la antigüedad temprana son los factores de mayor peso. A partir de los hallazgos se proponen cinco líneas de acción:

1. **Migrar clientes mes a mes a contratos anuales.** Es la palanca de mayor impacto: la tasa cae de 42,71% a 11,27% al pasar a contrato anual. Ofrecer incentivos por permanencia.
2. **Incentivar el pago automático.** Migrar clientes de cheque electrónico (45,29%) a débito automático con tarjeta (15,24%) reduce sustancialmente la cancelación.
3. **Reforzar el onboarding de clientes nuevos.** Los primeros 12 meses concentran el 47,44% de la cancelación; un acompañamiento temprano focalizado puede retener a este grupo.
4. **Promover el bundling de servicios de retención.** A más servicios contratados, menor cancelación (5,28% con seis servicios). Los paquetes integrados aumentan la permanencia.
5. **Revisar la propuesta de valor de Fiber optic.** Su cancelación del 41,89% pese a ser premium exige investigar la calidad del servicio y la percepción de precio.

10. Stack técnico y reproducción

Componente	Herramienta y uso
Base de datos	SQLite — EDA, ETL, modelado y análisis (motor central)
Lenguaje	Python (pandas, numpy, scipy) — validación cruzada y estadística
Visualización estática	matplotlib, seaborn — 18 gráficos del análisis
Dashboard	Tableau Public — historia con 6 dashboards ejecutivos
Modelado visual	dbdiagram.io — diagrama entidad-relación
Diagrama de flujo	Miro — pipeline del proceso
Entorno	VS Code + extensión SQLite

Entregables del proyecto

- 5 notebooks: EDA, ETL, modelado, exportación del modelo y análisis
- 5 archivos SQL: exploración, DDL, carga, KPIs e hipótesis
- Base de datos SQLite con las 8 tablas del modelo relacional
- Dataset limpio en CSV y Excel, y modelo exportado a Excel multi-hoja
- 18 visualizaciones en la carpeta assets
- Historia de Tableau Public con 6 dashboards

Fin del documento